

Propuesta de Proyecto Final de Ciencia de Datos

Gabriela Mariel Lopez Armenta

Proyecto: Predicción de Deserción de Clientes Bancarios (Churn)

4 de Noviembre de 2025

1. Título del Proyecto

Predicción de la Deserción de Clientes Bancarios (*Churn*) mediante Modelos de Machine Learning para la Optimización de Estrategias de Retención.

1.1. Problemática y Justificación

La deserción de clientes (*Churn*) es el principal desafío de rentabilidad en el sector financiero. Este proyecto busca no solo predecir qué clientes abandonarán el banco, sino **identificar los factores subyacentes** que impulsan esta decisión, proporcionando información accionable para campañas de retención. El problema es de naturaleza de **clasificación binaria**.

2. Pregunta de Investigación (Q.I.)

¿Cuáles son los **factores demográficos, financieros y de compromiso** que tienen el mayor impacto en la probabilidad de deserción de un cliente bancario, y cuál es el modelo de *Machine Learning* más eficiente (medido por *AUC* y *Recall*) para identificar a los clientes de alto riesgo?

3. Hipótesis

La deserción de clientes está impulsada principalmente por un **bajo nivel de compromiso financiero** con la entidad. Específicamente, se postula que la **combinación de un Saldo bajo, una baja Puntuación Crediticia y un número reducido de productos** será el predictor más robusto de *Churn*.

4. Fuente de Datos

- **Dataset:** Datos de *Churn Modelling* (10,000 entradas) de una entidad bancaria, disponible en plataformas públicas como Kaggle.

- **Variables Clave:** CreditScore, Age, Balance, NumOfProducts, IsActiveMember y la variable objetivo Exited (1=Churn, 0=No Churn).

5. Metodología de Desarrollo

El proyecto se desarrollará bajo un enfoque de modelado de **Clasificación**, utilizando el lenguaje Python y las librerías estándar de Ciencia de Datos (Pandas, Scikit-learn).

5.1. Fases del Proyecto

1. **Preparación de Datos:** Eliminación de identificadores (CustomerID). **Codificación** (*One-Hot Encoding*) de variables categóricas (Geography, Gender).
2. **Preprocesamiento:** División de los datos en Entrenamiento/Prueba (80/20). **Escalado** de variables numéricas mediante **StandardScaler** para evitar el sesgo por magnitud.
3. **Modelado y Comparación:** Se implementarán y compararán tres modelos de diversa complejidad:
 - **Modelo Base:** Regresión Logística.
 - **Modelos Avanzados:** Random Forest y **XGBoost**.

5.2. Criterios de Éxito y Evaluación

El desbalance de clases (*approx.* 80 % No-Churn vs. 20 % Churn) exige priorizar métricas que midan la capacidad del modelo para identificar a la minoría:

- **Métrica Primaria: AUC** (Área bajo la curva ROC), que mide la capacidad general del modelo para distinguir las dos clases.
- **Métrica Crítica: Recall** para la Clase 1 (*Churn*), que mide qué porcentaje de clientes en riesgo real fue identificado.
- **Criterio de Éxito:** Un **AUC superior a 0.85** y un **Recall** para la clase *Churn* de al menos **0.50**, superando el modelo base de Regresión Logística.

6. Anticipación de Resultados (Resultados Preliminares)

La experimentación inicial de los modelos arrojó los siguientes resultados comparativos:

Cuadro 1: Tabla Comparativa de Métricas de Modelos (Clase 1: Churn)

Modelo	Accuracy	Recall	Precision	AUC Score
Regresión Logística	0.81	0.20	0.55	0.7789
Random Forest	0.87	0.47	0.76	0.8653
XGBoost (Ganador)	0.87	0.55	0.72	0.8502

Conclusión Anticipada: El modelo **XGBoost** será seleccionado como la solución final, ya que su **Recall de 0.55** es el más alto, superando el criterio de éxito ($Recall \geq 0,50$). Esto indica la mayor capacidad para identificar clientes en riesgo, combinada con una alta *Accuracy*.

Factores de Riesgo Anticipados: La **Edad** sigue siendo el factor más dominante en la predicción, pero la validación de la hipótesis se centrará en la fuerte influencia conjunta de **Balance**, **NumOfProducts** y **CreditScore**. Esto demuestra que los factores de compromiso y riesgo financiero son los principales impulsores del *Churn*.